

RAG Portfolio

10 Proyectos de Retrieval-Augmented Generation

De básico a avanzado — PostgreSQL + pgvector + NVIDIA NIM

Python 3.9

FastAPI

PostgreSQL 17

pgvector

NVIDIA NIM

LangChain

SSE Streaming

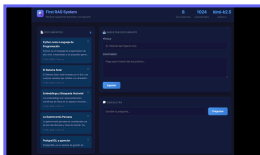
BeautifulSoup4

Manuel Argüelles


Data Engineer / Analytics Engineer

Lima, Perú


Los 10 Proyectos



01 Basic




02 PDF



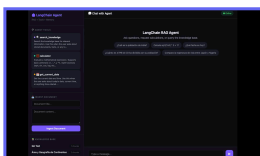
03 Multi-doc



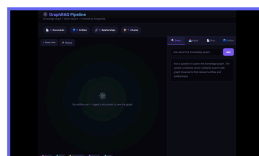
04 IBM



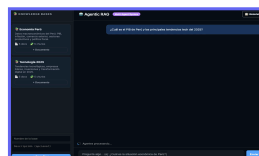
05 Real-time




06 LangChain



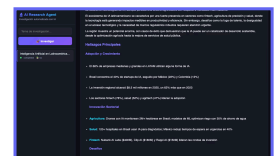
07 GraphRAG



08 Agentic



09 Multimodal



10 Research

Febrero 2026

github.com/manuelarguelles/rag-portfolio

Contenido

01 First RAG System

RAG básico desde cero — el patrón fundamental

02 Document Analysis

PDF Processing con chunking y trazabilidad

03 Multi-Document RAG

Colecciones temáticas + búsqueda filtrada

04 IBM RAG Guided

Pipeline enterprise: expansion + reranking + grounding

05 Real-Time Assistant

Streaming SSE token-by-token + memoria

06 LangChain Agent

ReAct Agent con tool selection autónoma

07 GraphRAG

Knowledge Graph + Vector Search híbrido

08 Agentic RAG

4 agentes autónomos colaborando

09 Multimodal RAG

Text + Images en espacio vectorial unificado

10 AI Research Agent

Investigación automatizada end-to-end

¿Qué es RAG?

RAG (Retrieval-Augmented Generation) combina búsqueda de información relevante en una base de conocimiento con generación de respuestas por un LLM. Esto permite responder con información específica y actualizada, reduciendo alucinaciones significativamente.

Pipeline RAG Fundamental:

Pregunta → Embedding (1024d) → Vector Search (pgvector)
→ Top-K Chunks → LLM (Kimi K2.5) → Respuesta Grounded

Stack Tecnológico

PostgreSQL 17 + pgvector

Base de datos vectorial con índice HNSW.
Búsqueda eficiente por similitud coseno.

NVIDIA NIM API (gratis)

nv-embedqa-e5-v5 (1024d) para embeddings.
Kimi K2.5 como LLM de generación.

Python 3.9 + FastAPI

Backend ligero con async. P06 usa Flask.
Sin frameworks pesados.

HTML/CSS/JS vanilla

Frontend responsive con dark theme.
Cada proyecto independiente.

Números Clave

10

Proyectos RAG

1024

Dimensiones embedding

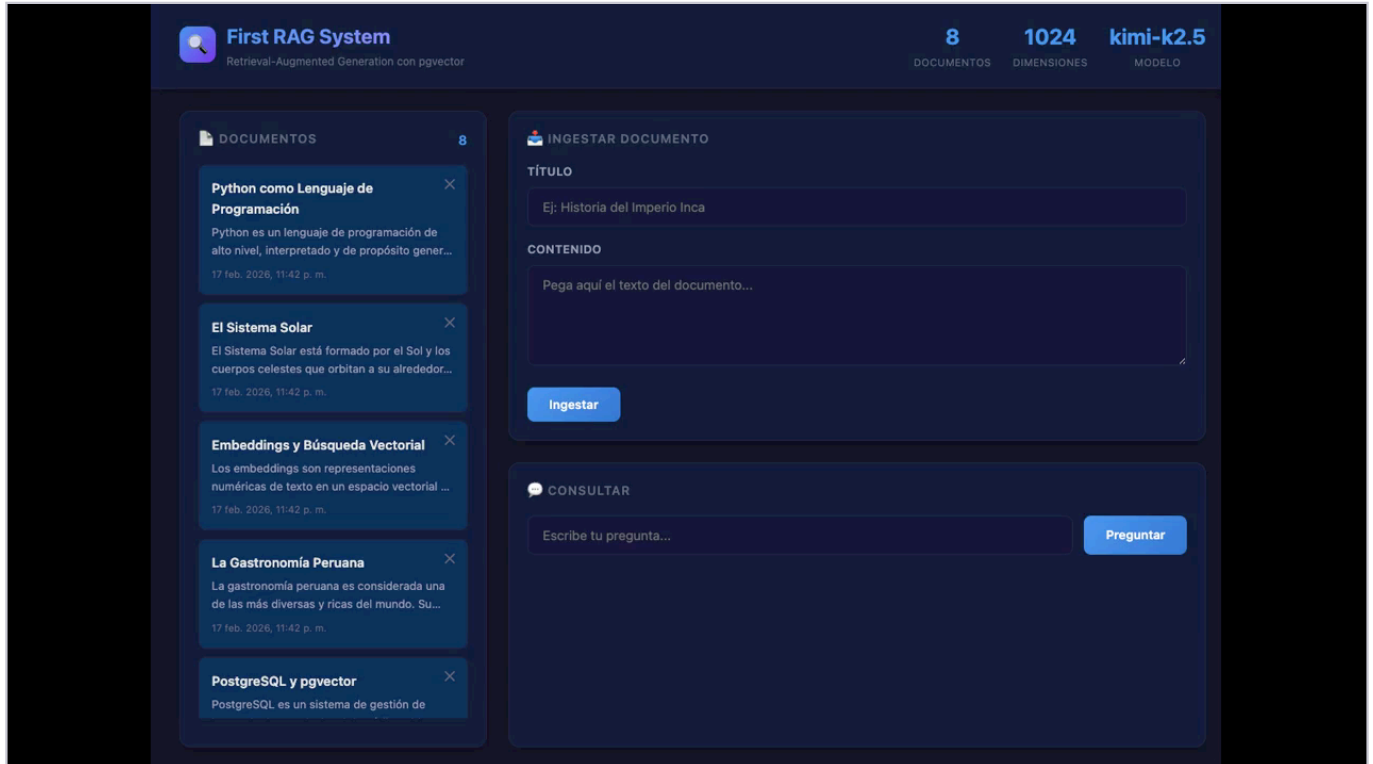
100%

Open source

0

Costo de API

01 — First RAG System



¿Qué es?

RAG básico construido desde cero, sin frameworks. Implementa el patrón fundamental: embedding de la pregunta → búsqueda por similitud coseno en pgvector → contexto al LLM → respuesta grounded con citas. Punto de partida ideal para entender RAG.

Implementación

- ▶ Ingestión de 8 temas (Transformers, pgvector, RAG, SSE, etc.)
- ▶ Búsqueda vectorial con similarity scores visibles
- ▶ Generación con citas al chunk fuente
- ▶ UI tipo chat con panel de resultados

Stack: FastAPI + psycpg2 + pgvector | Puerto: 8000

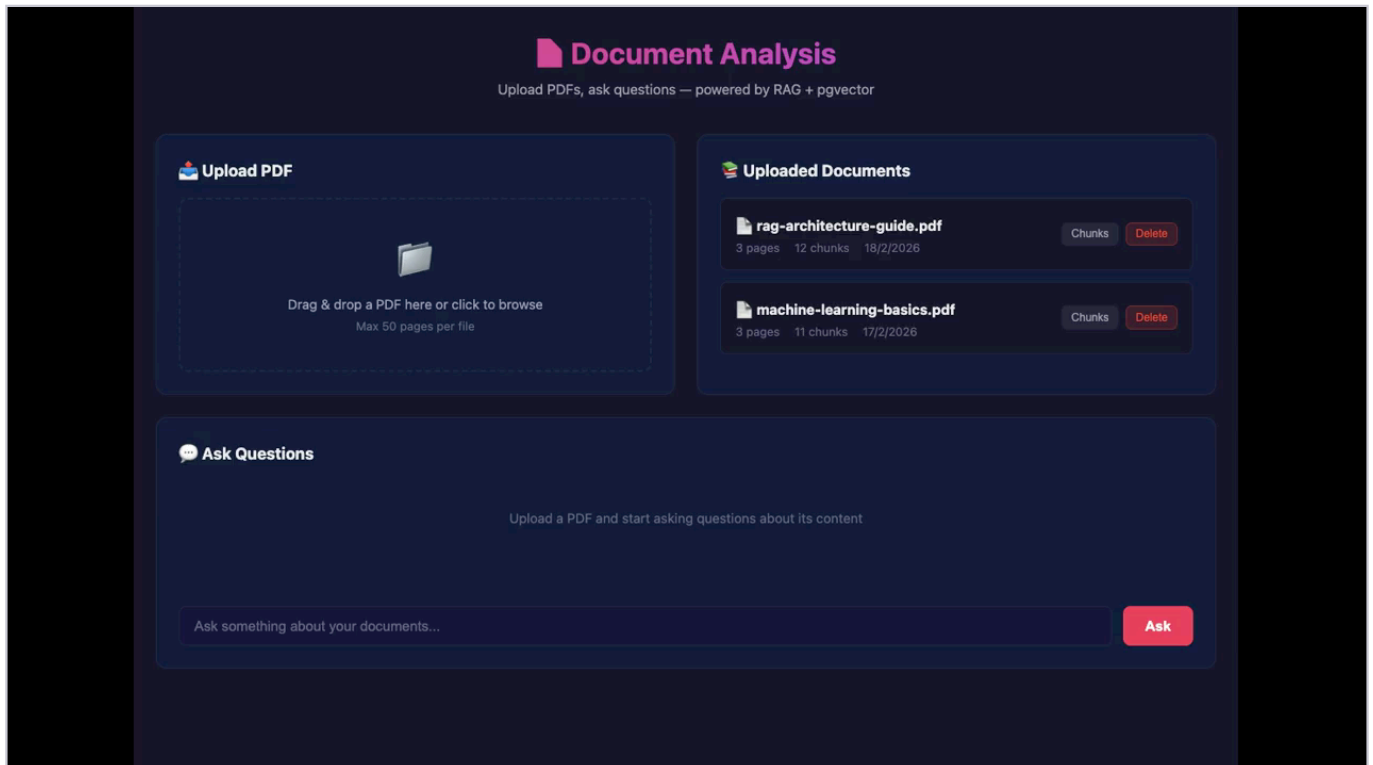
✓ Ventajas

- + Simple y didáctico
- + Sin frameworks
- + Código transparente

✗ Limitaciones

- Sin chunking inteligente
- Sin reranking
- Sin memoria

02 — Document Analysis



¿Qué es?

RAG con procesamiento real de PDFs. Upload → extracción con PyMuPDF → chunking 500 chars / 100 overlap → embedding → búsqueda con citas a la página exacta del PDF.

Implementación

- ▶ Pipeline: drag & drop → extracción → chunking → embedding
- ▶ Trazabilidad hasta página exacta del PDF
- ▶ Chunking con overlap preserva contexto
- ▶ 3 PDFs de ejemplo precargados

Stack: FastAPI + PyMuPDF + pgvector | Puerto: 8002

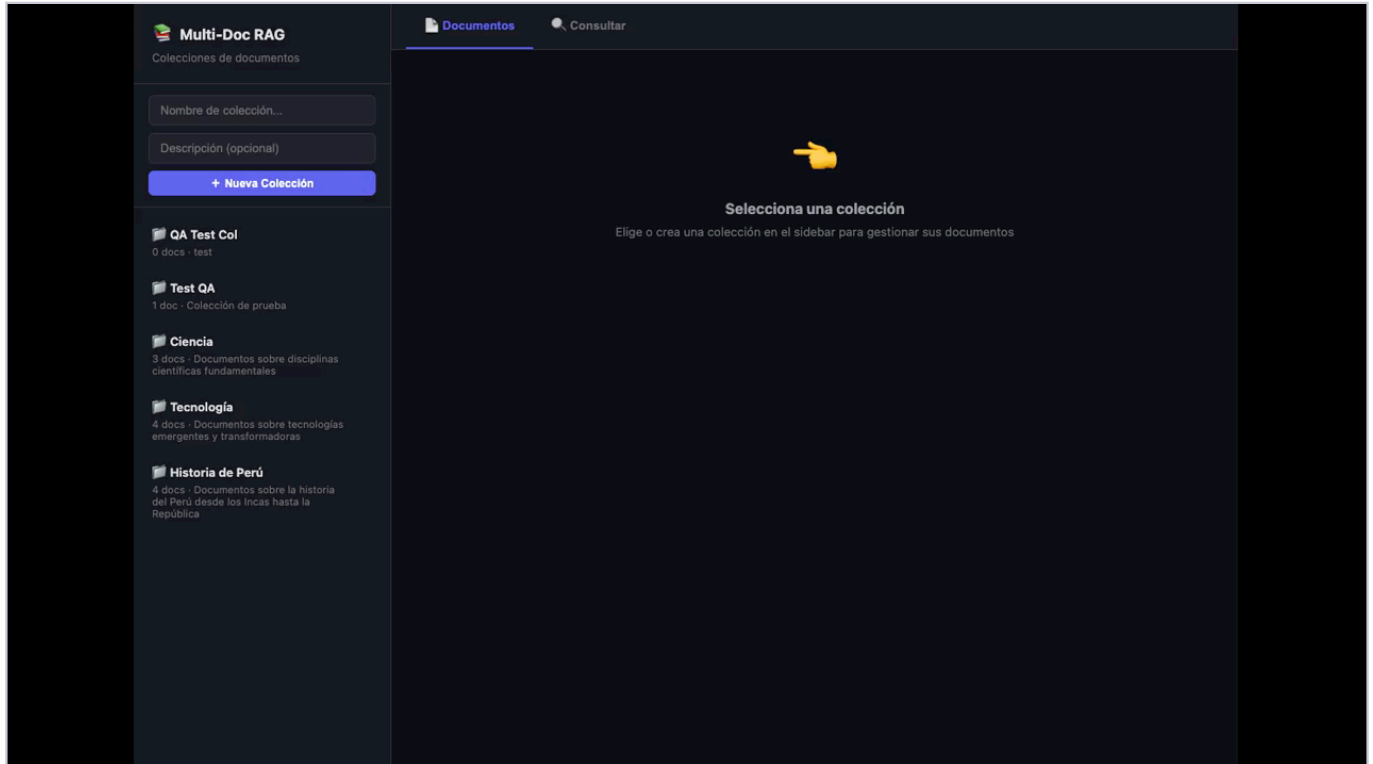
✓ Ventajas

- + Procesamiento real de docs
- + Trazabilidad doc→pág→chunk
- + Overlap preserva contexto

✗ Limitaciones

- Solo PDF
- Sin multi-documento
- Chunking fijo

03 — Multi-Document RAG



¿Qué es?

RAG con múltiples documentos en colecciones temáticas. Búsqueda filtrable por colección o corpus completo. Trazabilidad de 3 niveles: colección → documento → chunk.

Implementación

- ▶ CRUD de colecciones y documentos
- ▶ Búsqueda filtrable por colección
- ▶ 4 colecciones precargadas
- ▶ Trazabilidad de 3 niveles

Stack: FastAPI + psycpg2 + pgvector | Puerto: 8003

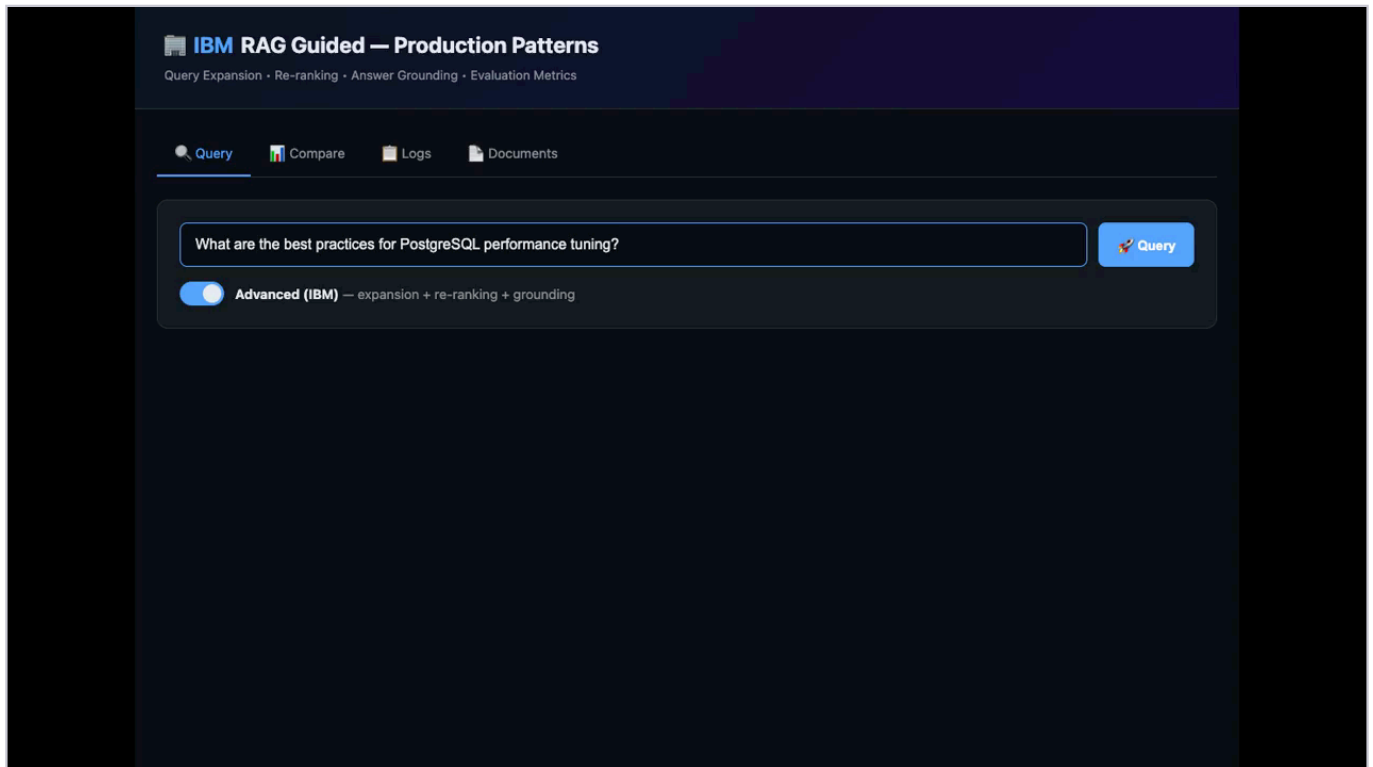
✓ Ventajas

- + Organización por colecciones
- + Búsqueda filtrada
- + Trazabilidad completa

✗ Limitaciones

- Sin reranking
- Sin cross-collection search

04 — IBM RAG Guided



¿Qué es?

Pipeline enterprise: Query Expansion (2-3 variantes), Re-ranking (LLM puntúa 1-10), Grounding Check (verifica fidelidad). Toggle entre modo Simple y Advanced.

Implementación

- ▶ Dos pipelines: Simple vs Advanced
- ▶ Logs visibles de cada etapa del pipeline
- ▶ Métricas de latencia por paso
- ▶ Grounding score de fidelidad

Stack: FastAPI + pgvector (4-5 LLM calls) | Puerto: 8004

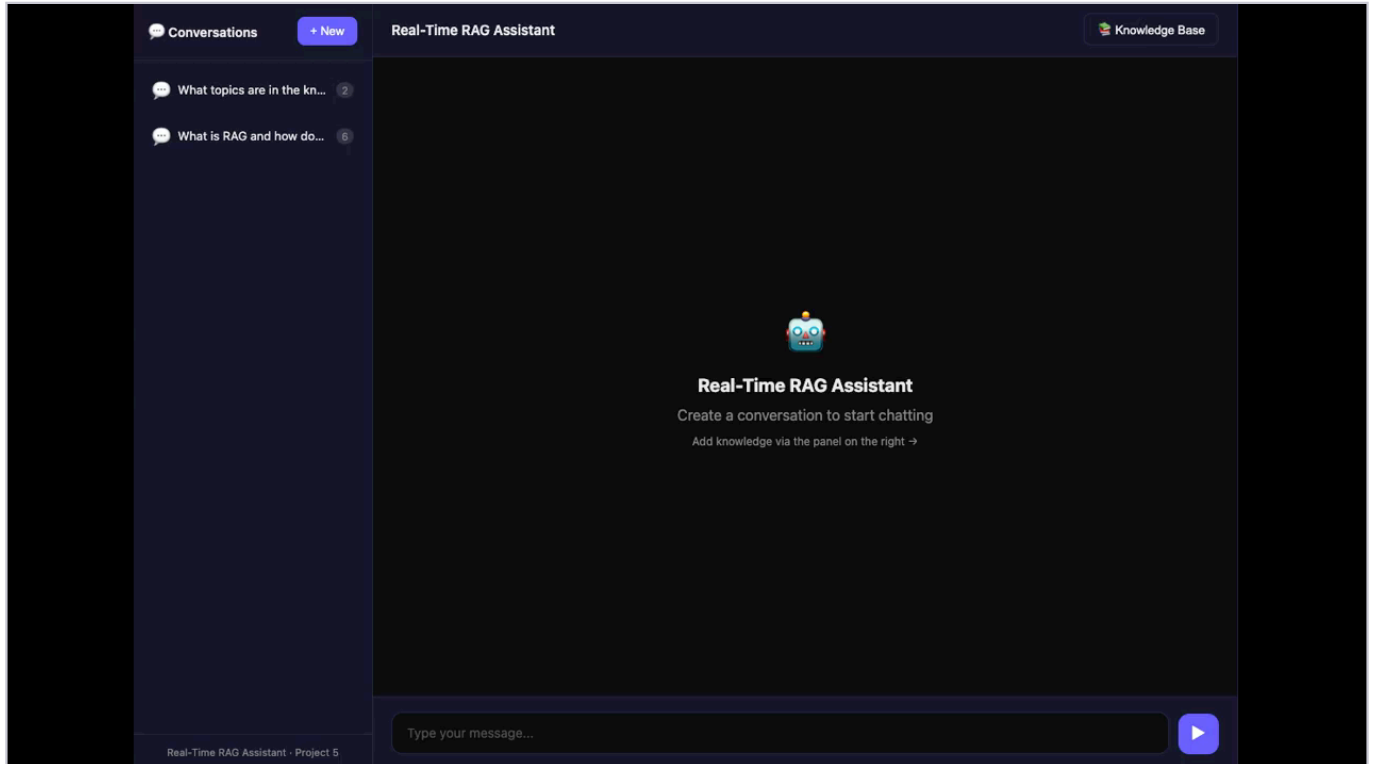
✓ Ventajas

- + Calidad superior
- + Multi-ángulo
- + Reduce alucinaciones

✗ Limitaciones

- Lento (~60-90s)
- Costoso (N LLM calls)
- Debug complejo

05 — Real-Time Assistant



¿Qué es?

Asistente con streaming SSE token-by-token como ChatGPT. Memoria de conversación (5 msgs). Knowledge base editable en caliente sin reiniciar.

Implementación

- ▶ Chat UI estilo ChatGPT con sidebar
- ▶ Streaming vía Server-Sent Events
- ▶ Memoria conversacional (5 msgs)
- ▶ KB editable en caliente

Stack: FastAPI + SSE + pgvector | Puerto: 8005

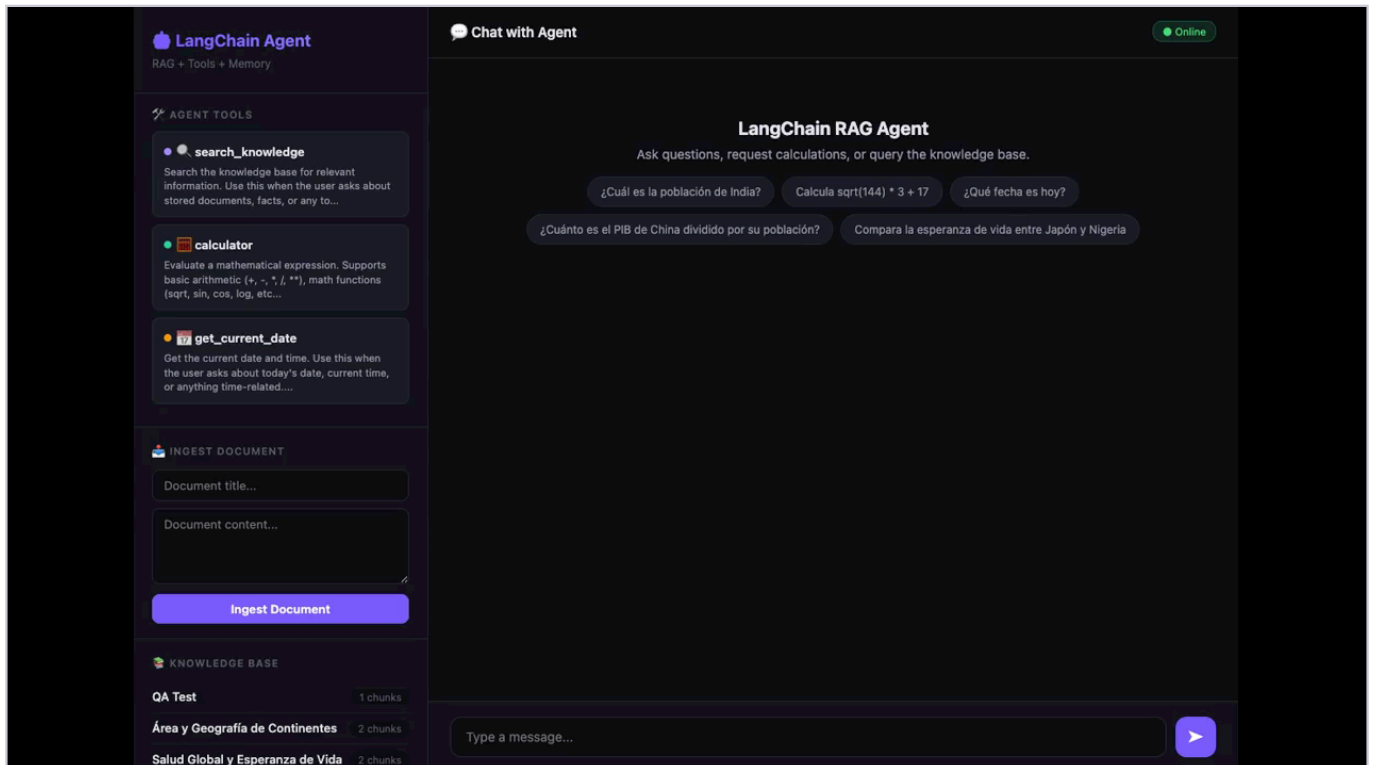
✓ Ventajas

- + UX superior (streaming)
- + Memoria conversacional
- + KB en caliente

✗ Limitaciones

- Solo texto directo
- Memoria limitada

06 — LangChain Agent



¿Qué es?

Agente ReAct con LangChain + LangGraph. Decide autónomamente entre 3 tools: búsqueda vectorial, calculadora, y fecha actual. Custom NvidiaEmbeddings.

Implementación

- ▶ 3 tools: search, calculator, date
- ▶ NvidiaEmbeddings custom (asimétrico)
- ▶ Pipeline de ingestión LangChain
- ▶ 6 documentos precargados

Stack: Flask + LangChain + LangGraph | Puerto: 5006

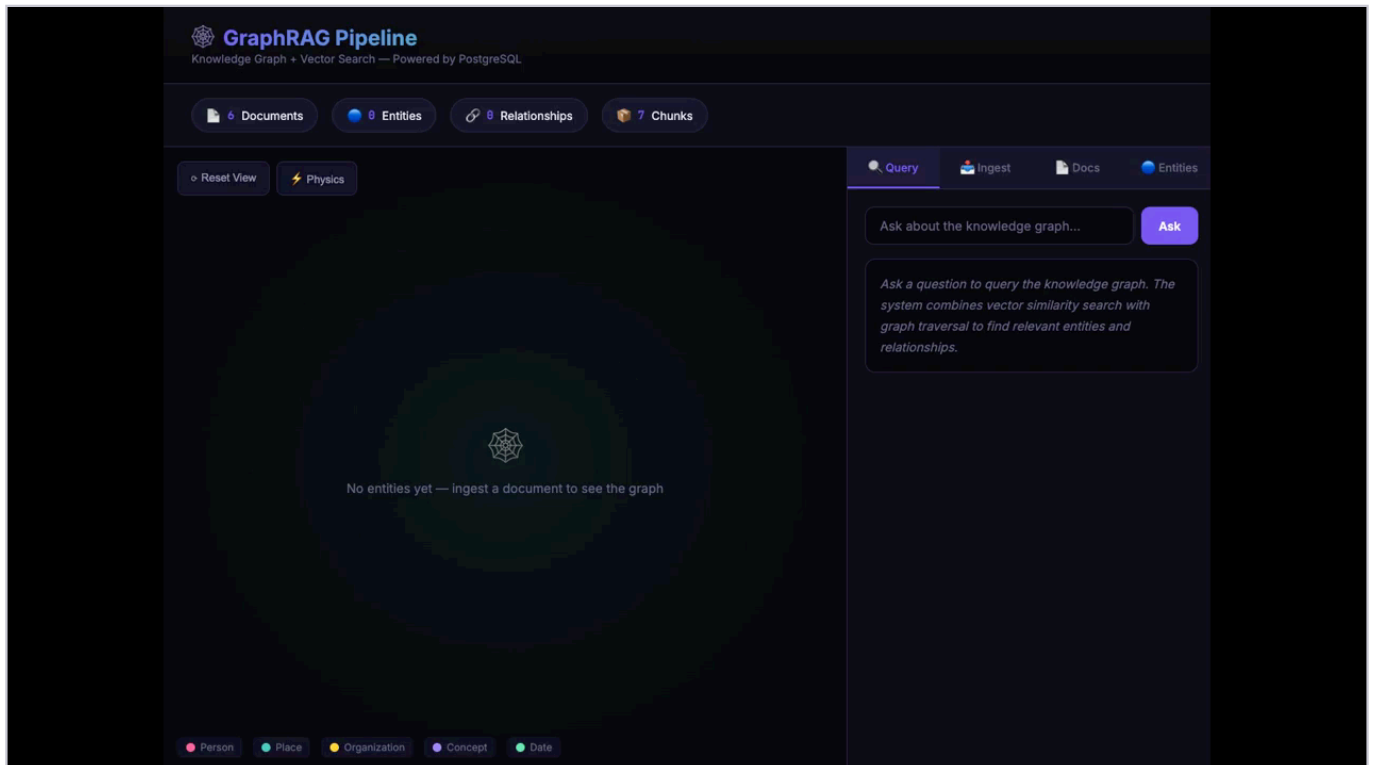
✓ Ventajas

- + Framework maduro
- + Tool selection
- + Patrón ReAct

✗ Limitaciones

- Vendor lock-in
- Overhead
- Debug difícil

07 — GraphRAG



¿Qué es?

Híbrido: vector search + knowledge graph. Extrae entidades y relaciones vía LLM. Multi-hop reasoning implementado en PostgreSQL puro (sin Neo4j).

Implementación

- ▶ Extracción de entidades y relaciones
- ▶ Grafo en PostgreSQL (sin Neo4j/Docker)
- ▶ Búsqueda híbrida: cosine + graph JOINS
- ▶ 6 documentos precargados

Stack: FastAPI + pgvector + SQL JOINS | Puerto: 5007

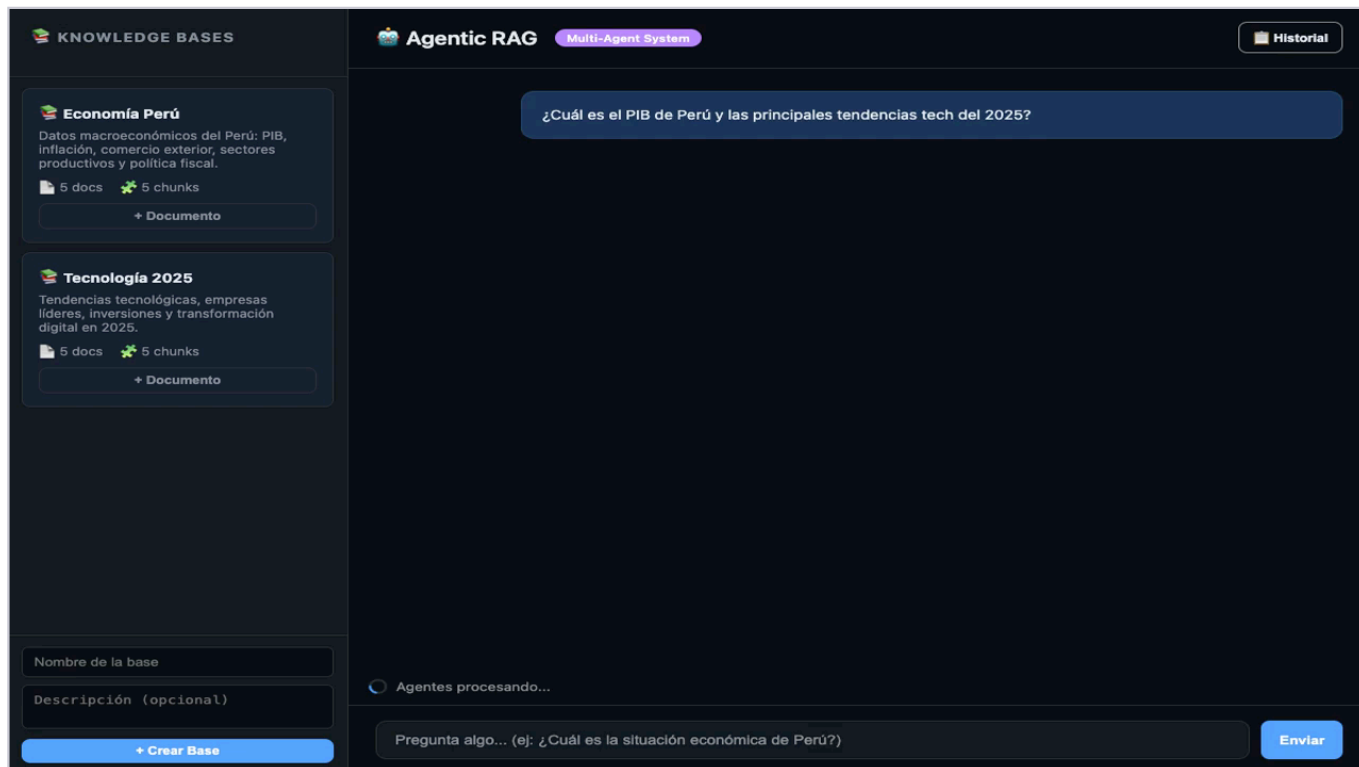
✓ Ventajas

- + Multi-hop reasoning
- + Todo en PostgreSQL
- + Enriquece contexto

✗ Limitaciones

- Extracción lenta
- Depende del LLM
- Más complejo

08 — Agentic RAG



¿Qué es?

4 agentes: Router (planifica), Research (busca), Analyst (analiza), Writer (compone). Python puro — sin LangChain, sin CrewAI. Trace visible de cada decisión.

Implementación

- ▶ 4 agentes especializados
- ▶ 2 knowledge bases temáticas
- ▶ Panel de trace en tiempo real
- ▶ Historial de queries

Stack: FastAPI + pgvector (Python puro) | Puerto: 8008

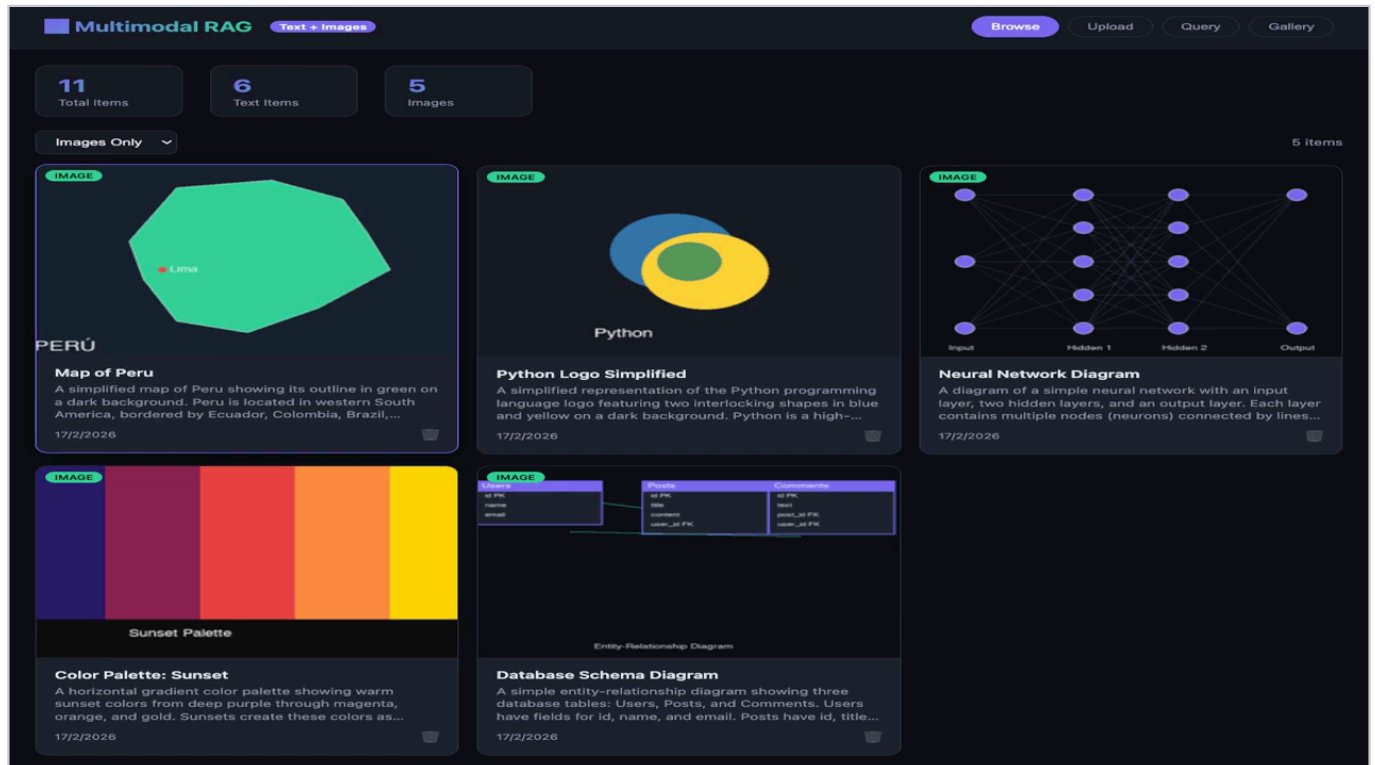
✓ Ventajas

- + Divide y vencerás
- + Trace visible
- + Sin frameworks

✗ Limitaciones

- 4+ LLM calls (~90s)
- Costoso en tokens
- Orquestación compleja

09 — Multimodal RAG



¿Qué es?

Unifica texto e imágenes en un espacio vectorial. Imágenes indexadas via descripción textual (text-bridge). Galería con filtros y búsqueda semántica unificada.

Implementación

- ▶ 11 items: 6 textos + 5 imágenes
- ▶ 4 vistas: Browse, Upload, Query, Gallery
- ▶ Filtro por tipo (All/Text/Images)
- ▶ Imágenes en BYTEA (PostgreSQL)

Stack: FastAPI + pgvector (text-bridge) | Puerto: 5009

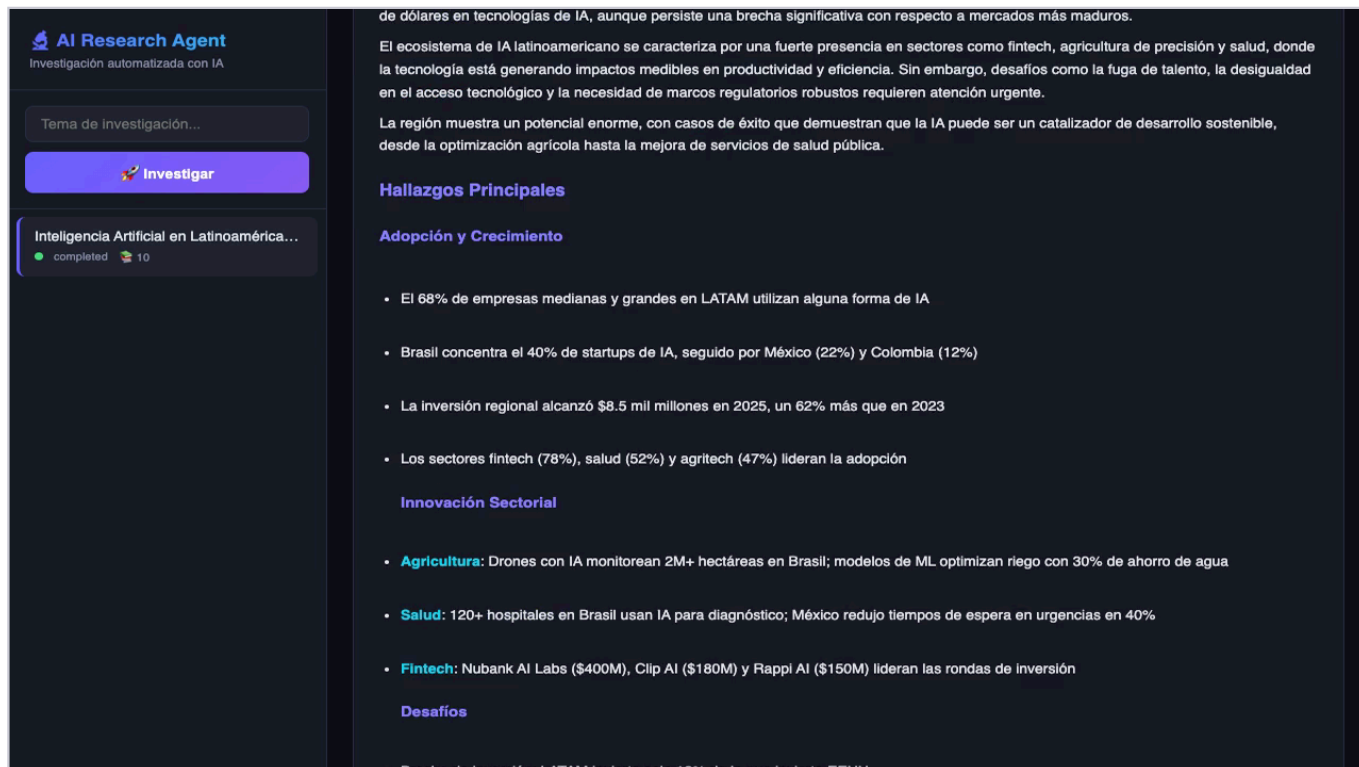
✓ Ventajas

- + Búsqueda unificada
- + UI tipo galería
- + Sin modelo de visión

✗ Limitaciones

- No embedding visual
- Depende de descripción
- Sin image-to-image

10 — AI Research Agent



¿Qué es?

Investigación automatizada: genera queries → scrapea web → chunkea → embede → analiza → genera reporte con resumen ejecutivo y hallazgos categorizados.

Implementación

- ▶ Pipeline completo de investigación
- ▶ Demo: 'IA en Latinoamérica 2025'
- ▶ 5 hallazgos categorizados
- ▶ Reporte Markdown estructurado

Stack: FastAPI + httpx + BS4 + pgvector | Puerto: 8010

✓ Ventajas

- + End-to-end automático
- + Hallazgos categorizados
- + Reporte exportable

✗ Limitaciones

- Depende de scraping
- Fuentes variables
- Tarda varios minutos

Resumen Comparativo

Cada proyecto agrega complejidad sobre el anterior. El RAG ideal depende del caso de uso — no siempre más complejo es mejor.

Progresión de Complejidad



¿Cuál usar según el caso?

Aprender RAG desde cero	→ 01 First RAG
Documentos internos (PDFs)	→ 02 Document Analysis
Múltiples fuentes organizadas	→ 03 Multi-Document
Producción enterprise	→ 04 IBM RAG Guided
Chatbot conversacional	→ 05 Real-Time Assistant
Múltiples herramientas	→ 06 LangChain Agent
Preguntas sobre relaciones	→ 07 GraphRAG
Consultas complejas	→ 08 Agentic RAG
Contenido mixto (text+images)	→ 09 Multimodal RAG
Investigación autónoma	→ 10 Research Agent

Manuel Argüelles

Data Engineer / Analytics Engineer • Lima, Perú

GitHub: [manuelarguelles](#) • **LinkedIn:** [manuelarguelles](#)